## Задание 2. Размещение виртуальных машин на вычислительном кластере (максимум 30 баллов).

Для организации сервиса облачных вычислений необходимо предложить проект системы, обеспечивающей запуск виртуальных машин на масштабируемом вычислительном кластере.

## Исходные данные:

- имеется парк серверов (N штук,  $10^3 < N < 10^5$ ), объединенных в кластер общей сетью. На каждом сервере -- стандартная ОС и одинаковое количество вычислительных ядер и оперативной памяти (128 Gb);
- существующий инструмент (программа), умеющая запускать виртуальную машину с заданным размером памяти и вычислительным заданием ("задание", оно же "вычислительное задание" -- это полезная нагрузка, которую может исполнять виртуальная машина. Например, решение какого-то численного уравнения. Не путать с запросом к API);
- поток случайных запросов на создание виртуальных машин с параметрами:
- {"id": <unique machine id, numeric>, "size": <RAM, Gb, numeric>, "task": <payload, string>}, где size может принимать значения степеней 2 (1, 2, 4 ... 128).

## Необходимо:

- 1. Спроектировать и описать систему, предоставляющую API по созданию виртуальных машин, а также обеспечивающую оптимальное размещение машин на кластере и передачу файлов заданий на сервера.
- 2. АРІ должно принимать запросы в описанном формате и отвечать пользователю:
- {"result": "OK", "host\_id": <nmb of target host in cluster, 1...N, numeric>}, где nmb -- номер сервера, на который размещена виртуальная машина) в случае возможности разместить машину,
- {"result": "NOT\_OK"}, в случае невозможности разместить машину с такими требованиями по RAM.
- 3. Описать алгоритм размещения виртуальных машин на кластере. Алгоритм должен обеспечивать оптимальное размещение машин на кластере для оптимальной утилизации памяти. "Утилизация" означает среднюю "степень загруженности" используемых серверов чем она выше, тем меньше неиспользуемой RAM на сервере. утилизация в 1 означает что все ресурсы сервера используются (нет свободных), а утилизация в 0.75 означает что на сервере есть 1/4 свободной памяти, т.е. 32 Gb;
- 4. Реализовать алгоритм в отдельном микросервисе с аналогичным API для автоматической верификации алгоритма.

## Требования к структуре оформления решения с указанием критериев оценивания и максимального количества баллов за каждую часть решения:

- 1. Введение. Описание архитектуры предлагаемой системы с основными компонентами их взаимодействием до 2 баллов.
  - 2. Основная часть.
    - 2.1. Выбор критерия оценки эффективности размещения машин на кластере до 3 баллов.
    - 2.2. Обоснование и описание алгоритма размещения машин на кластере до **3** баллов.
    - 2.3. Описание в форме UML-диаграмм моделей процессов: хранения и обработки запросов на размещение виртуальных машин, обеспечения отказоустойчивости кластера при типовых отказах (сервера, процесса выполняемого задания) до 3 баллов.
    - 2.4. Разработка прототипа для API размещения машин на кластере серверов и тестирование прототипа API на функциональность с представлением результатов теста исходных кодов, опубликованных в любом репозитории, работающим с VCS git с разрешением публичного доступа, и инструкций по воспроизведению проверяющими экспертами, и содержащий Dockerfile, полностью реализующий сборку и запуск прототипа таким образом, чтобы запущенный из этого Dockerfile контейнер предоставлял требуемый API на порту 9024 до 15 баллов.
    - 2.5. Выбор параметров для сбора статистики и оценки эффективности использования серверов в кластере, создание сценариев масштабирования (добавления и сокращения серверов) кластера до 3 баллов.
  - 3. Заключение (выводы по достижению поставленных целей) до 1 баллов.